README_TURKISH

Прогнозирование цен на недвижимость в Турции
Учебный проект по анализу рынка недвижимости Турции и прогнозированию цен на основе датасета объявлений платформы Zingat. Включает перевод и очистку данных, разведочный анализ (EDA), предобработку, обучение и сравнение моделей регрессии, а также приложение для оценки стоимости объекта.
О проекте
Цель: построить модель, которая по характеристикам объекта (тип и подтип, площадь, число комнат, этаж, этажность, возраст здания, отопление, город) предсказывает цену в турецких лирах (TRY) для объявлений о продаже и аренде.
Данные
Источник: датасет Zingat, 403 487 объявлений, 17 столбцов.
Признаки: тип и подтип недвижимости, адрес (провинция / район / квартал), площадь, число комнат, этаж, этажность, возраст здания, тип отопления, цена и валюта, даты публикации.
Столбец furnished полностью пустой, поэтому удалён.
После очистки осталось 253 886 объектов.

Что было сделано
Перевод данных с турецкого на русский (deep-translator, перевод только уникальных значений).

Очистка:
адрес разделён на провинцию, район и квартал;
цены ≤ 0 и площади < 10 или > 1000 м² помечены как пропуски;
удалены выбросы цены выше 99-го перцентиля;
текстовые значения («20 и более», «Высокий первый этаж») заменены числами;
пропуски: площадь - медиана по группе (тип, город), возраст, этажность и этаж - медиана, отопление - мода;
строки без цены удалены.
EDA: распределения цены, площади, возраста здания и числа комнат, средняя цена по городам, зависимость цены от площади. Цена сильно скошена вправо, поэтому целевая переменная логарифмируется.

Предобработка и признаки:
log_price = log1p(price);
новые признаки: is_rent, is_new_building, floor_ratio, is_penthouse, is_ground_floor, is_high_floor, size_per_room, age_size_ratio, floor_size_ratio;
редкие города и варианты комнатности объединены в группы «Другое»;

проверка мультиколлинеарности (VIF);
One-Hot кодирование категорий (итого 156 признаков), масштабирование числовых; разбиение 70 / 15 / 15 (train / validation / test).
Моделирование: Ridge, Decision Tree, Random Forest, Gradient Boosting, XGBoost, LightGBM. Подбор гиперпараметров с кросс-валидацией (cv=3), сравнение метрик в log-шкале и в лирах.
Приложение для оценки цены (см. ниже).

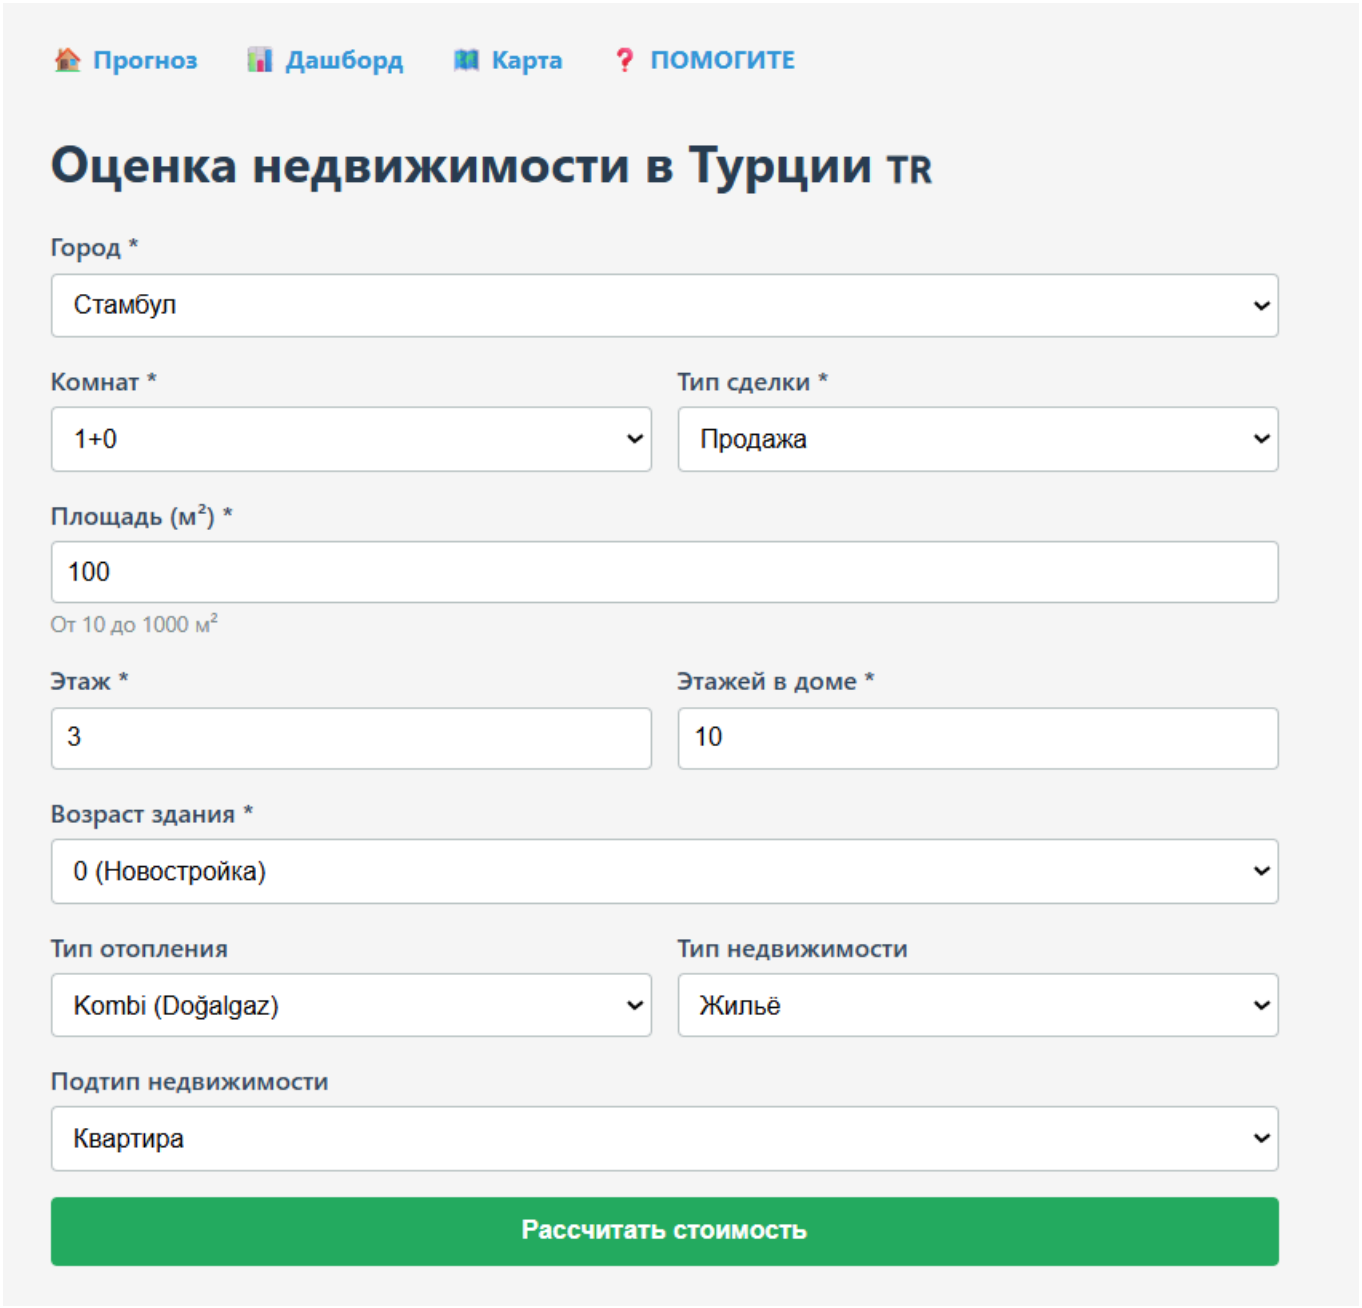
Результаты
Метрики на валидационной выборке (в лирах, TRY):
Модель
MAE, TRY
RMSE, TRY
R^2 (TRY)
R^2 (log)
Random Forest (tuned)
64 223
161 165
0.7535
0.9432
Random Forest
64 554
161 991
0.7509
0.9423
XGBoost
69 678
164 481
0.7432
0.9503
LightGBM
78 535
181 084
0.6887
0.9435
Decision Tree (tuned)
75 730
187 345
0.6668
0.9140
Gradient Boosting

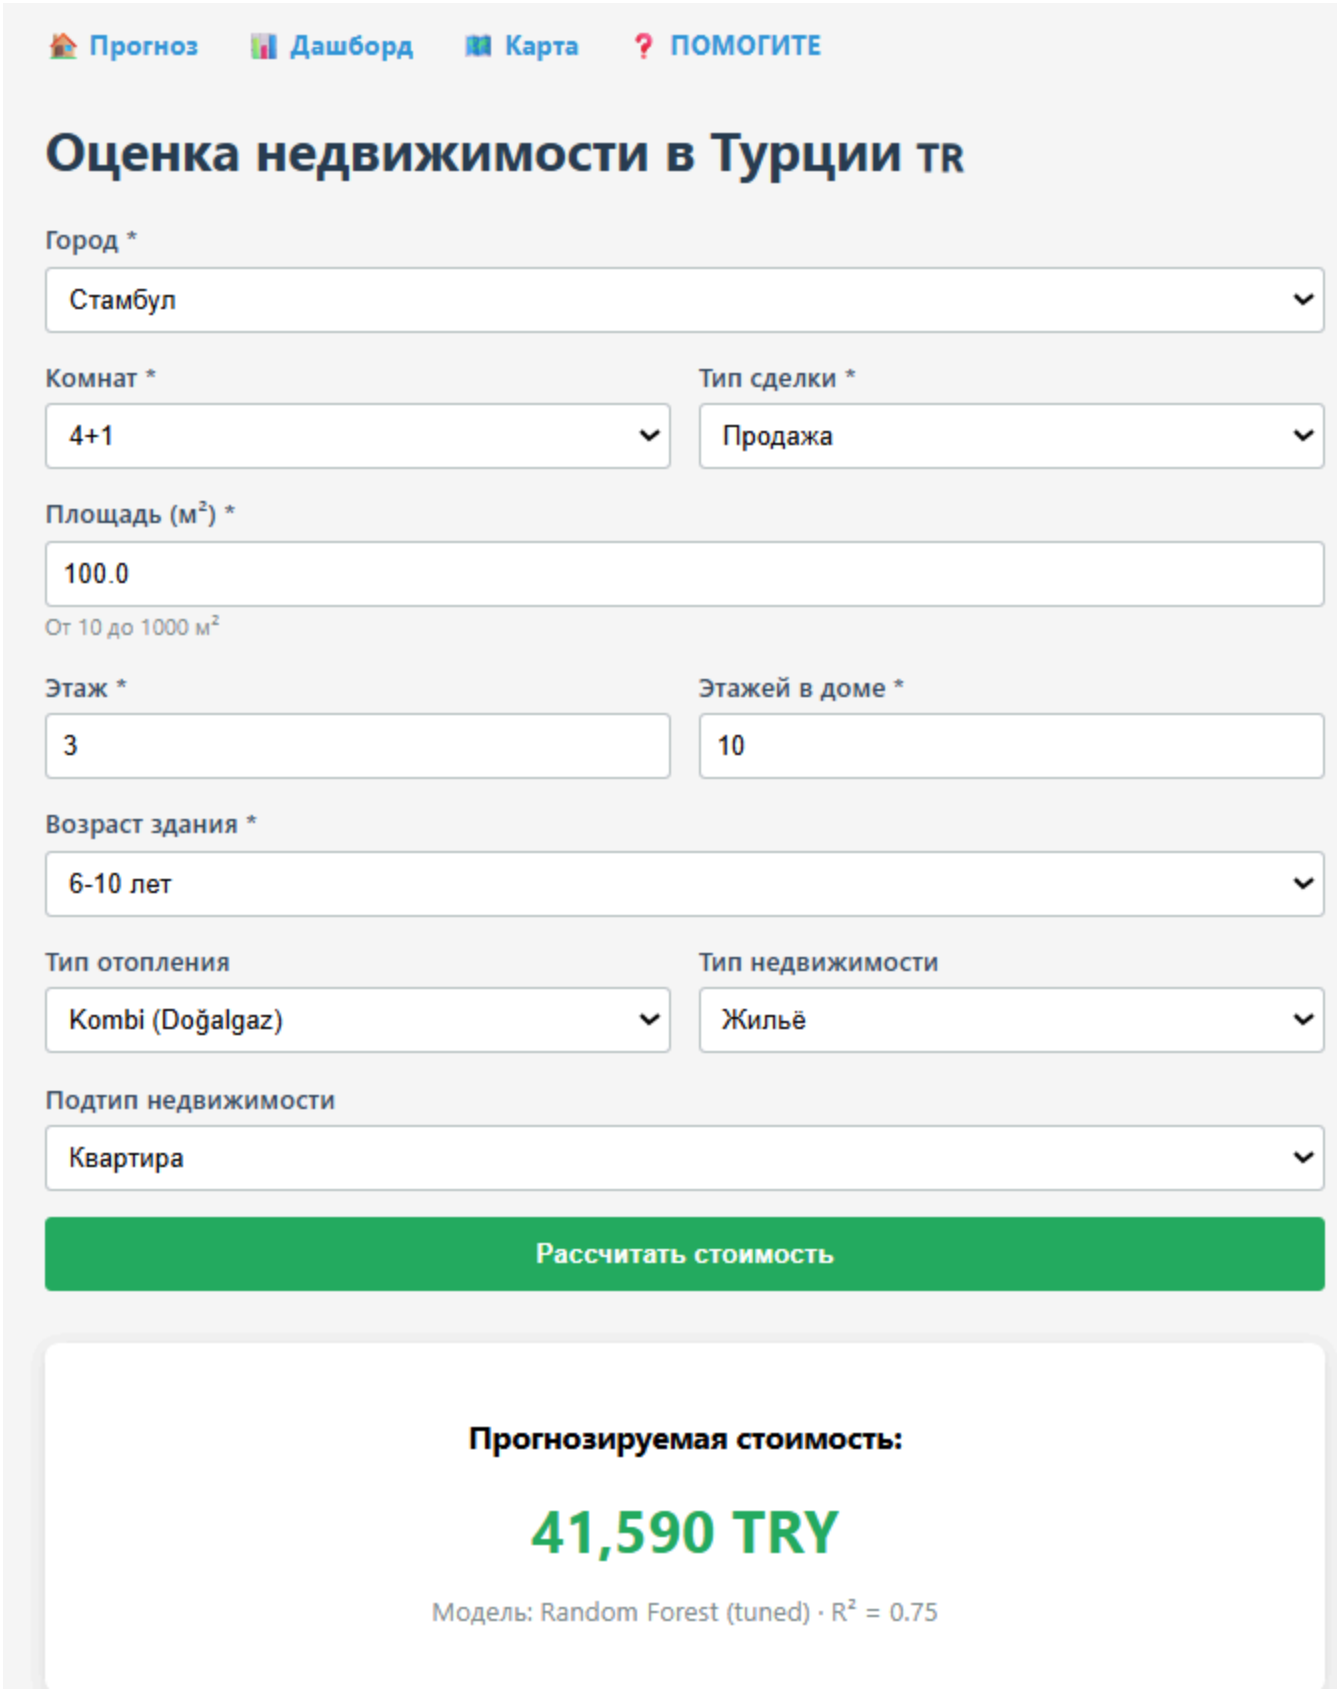
90 572
205 422
0.5995
0.8991
Ridge (tuned)
100 574
234 806
0.4767
0.8533

Лучшая модель: Random Forest (n_estimators=200, max_depth=None). Выбрана по наибольшему R^2 в лирах.

Ключевые выводы:
Самый важный признак - is_rent (≈ 78 % важности): цены продажи и аренды отличаются примерно на два порядка.
Среди остальных признаков заметный вклад дают число комнат, площадь, тип отопления и отношение возраста здания к площади.
В log-шкале качество высокое ($R^2 \approx 0.94$), но в лирах ниже ($R^2 \approx 0.75$): ошибки на дорогих объектах перевешивают.
MAPE в лирах очень большая (≈ 660 %), так как у дешёвых объектов (аренда) небольшая абсолютная ошибка даёт огромную относительную. Поэтому основные метрики - MAE, RMSE и R^2.

Приложение


Прогноз
Дашборд
Карта
ПОМОГИТЕ
Оценка недвижимости в Турции TR
Город *
Стамбул
Комнат *
1+0
Тип сделки *
Продажа
Площадь (м²) *
100
От 10 до 1000 м²
Этаж *
3
Этажей в доме *
10
Возраст здания *
0 (Новостройка)
Тип отопления
Kombi (Doğalgaz)
Тип недвижимости
Жильё
Подтип недвижимости
Квартира
Рассчитать стоимость



Краткое описание: пользователь вводит характеристики объекта и получает прогноз цены.

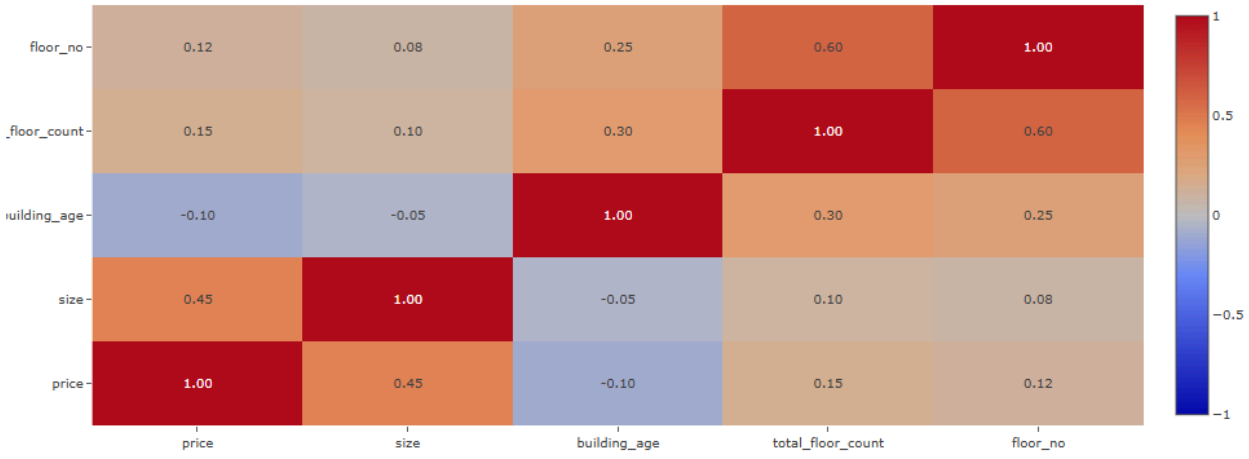
Прогноз | Дашборд | Карта | Help

Аналитический дашборд

Обзор датасета

ВСЕГО ОБЪЕКТОВ	СРЕДНЯЯ ЦЕНА	МЕДИАНА ЦЕНЫ	СРЕДНЯЯ ПЛОЩАДЬ
253,886	262,006 TRY	198,000 TRY	121.5 м²

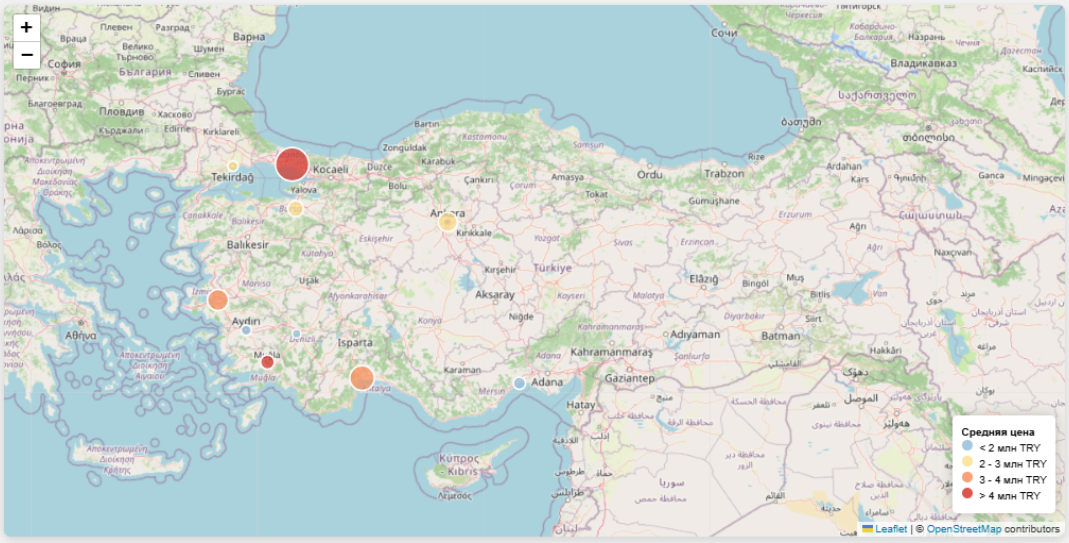
Тепловая карта корреляций признаков

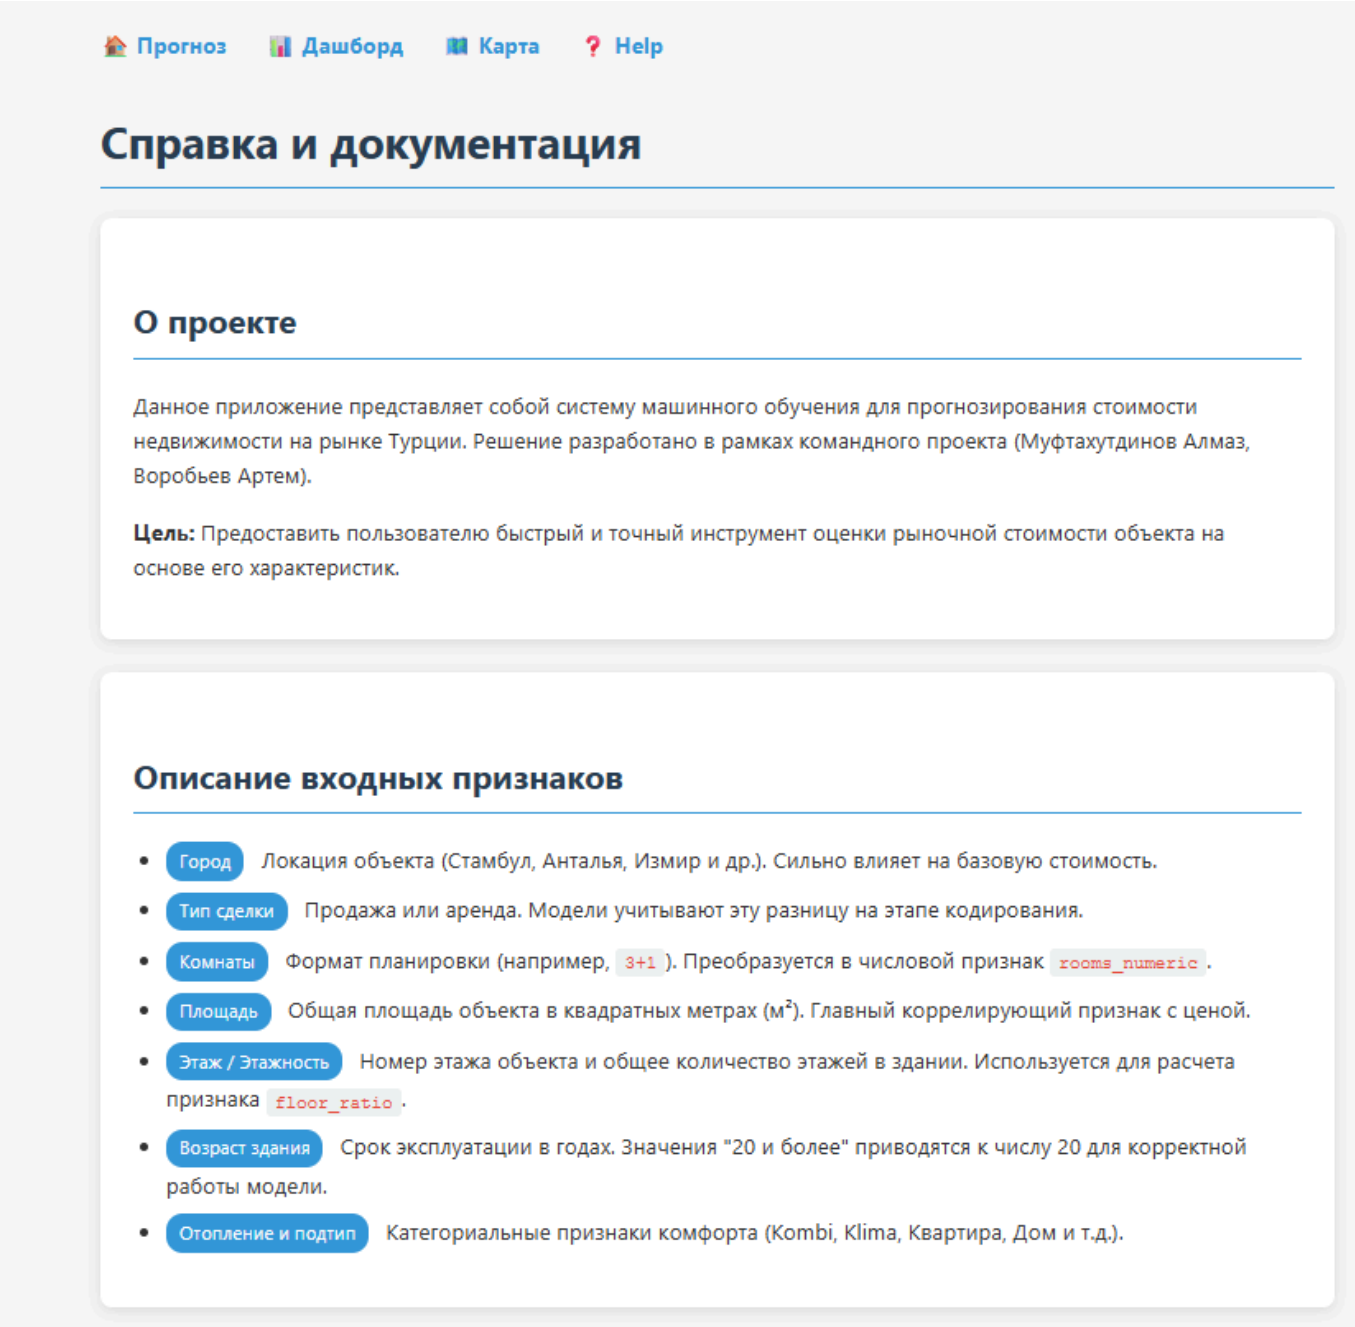


шборд | Карта | Help

Распределение недвижимости по городам Турции

Размер круга отражает количество объектов, а цвет — среднюю стоимость.





Запуск
pip install -r requirements.txt
streamlit run app.py

Структура проекта:
├── images/
├── TEAMwork4_completed.ipynb
├── app.py
├── best_model.pkl
├── scaler.pkl
├── feature_columns.pkl
└── README.md

Ограничения

Цены в исходных лирах (TRY) без пересчёта на дату объявления и без учёта инфляции.
Автоматический перевод названий местами неточен.
Продажа и аренда обучаются одной моделью, из-за этого в лирах ошибка на дорогих объектах высокая.
Часть строк с пропусками (например, в числе комнат) исключена перед обучением моделей, поэтому обучающая выборка заметно меньше очищенного датасета.

Возможные улучшения

Отдельные модели для продажи и аренды.
Курс валюты и инфляция на дату объявления.
Заполнение пропусков вместо удаления строк.
Дополнительные признаки (состояние объекта, координаты).

Стек

Python, pandas, NumPy, SciPy, scikit-learn, XGBoost, LightGBM, matplotlib, seaborn, joblib, deep-translator.

Авторы

Муфтахутдинов Алмаз, Воробьев Артем, группа 23П-2